ОТБОРОЧНОЕ СОРЕВНОВАНИЕ · LEARNING ANALYTICS

Кто не закончит курс

Студенты онлайн-университета записываются на курсы, занимаются в виртуальной образовательной среде и сдают задания. По тому, что известно о студенте к 60-му дню курса, нужно оценить, насколько вероятно, что он его не сдаст или бросит.

Дедлайн: **воскресенье, 25.10, 23:59 МСК**

01

Задача

У

Университет

Ведёт десятки тысяч студентов на дистанционных курсах. У тьюторов не хватает времени на всех, поэтому важно заранее понять, кому из студентов нужна помощь, пока ещё не поздно.

С

Студент

Записывается на поток курса, открывает материалы в виртуальной образовательной среде (VLE), сдаёт промежуточные задания и в конце экзамен. Каждое его действие попадает в логи.

?

Что предсказать

Строка `train` или `test` — одна запись студента на поток курса, которая на 60-й день ещё действует. Нужно оценить риск того, что курс студент не завершит.

target

1 студент провалил курс или бросил его после 60-го дня.

0 студент сдал курс, в том числе с отличием.

Таргет известен только для train. Доля единиц в train — **43,5%**.

Зачем это нужно

Такие модели лежат в основе систем раннего предупреждения. Университет сортирует студентов по оценке риска, и тьюторы в первую очередь связываются с теми, у кого он выше. Чем раньше и точнее модель находит таких студентов, тем больше из них удаётся удержать.

02

Данные

Реальные обезличенные данные онлайн-университета: семь курсов, по несколько потоков 2013–2014 годов. Семь таблиц, связанных ключами. Идентификаторы студентов заменены случайными числами.

17 566
записей в train с таргетом

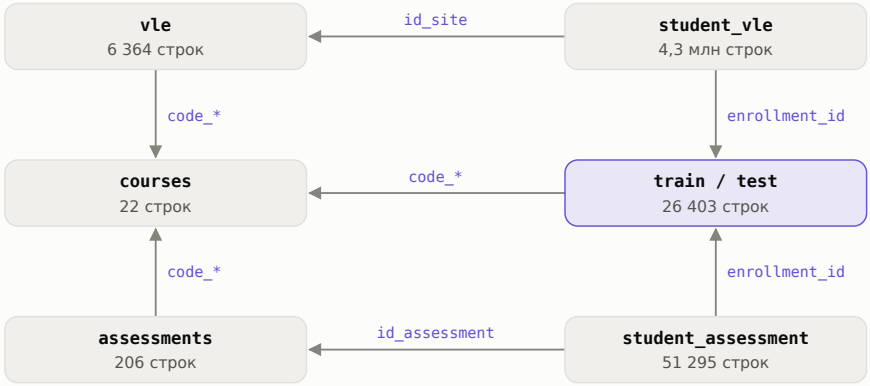
8 837
записей в test, по ним нужен прогноз

4,3 млн
строк логов: клики и сдачи заданий

9 МБ
архив с данными

Как связаны таблицы

Стрелка ведёт от таблицы к той, к которой она привязана. Подписи на стрелках — ключи для связи.



code_* — пара code_module, code_presentation, то есть курс и его поток.

Состав архива

```
data/
├── train.parquet
├── test.parquet
├── courses.parquet
├── assessments.parquet
├── student_assessment.parquet
├── vle.parquet
├── student_vle.parquet
├── columns_description.csv
└── sample_submission.csv
```

В `columns_description.csv` описана каждая колонка каждой таблицы. Начните с неё.

Что важно знать

- Все даты указаны в днях от начала потока. Отрицательные значения означают время до старта.
- Логи обрезаны по 60-му дню: в `student_vle` и `student_assessment` есть только события до него. Расписание заданий и список материалов даны целиком, они известны заранее.
- В train и test входят только записи, не отменённые до 60-го дня.
- Train — потоки 2013B, 2013J и 2014B, test — более поздний поток 2014J. Разбиение сделано по времени.
- Один студент может встречаться в нескольких строках: разные курсы или повторная попытка. Ключ студента — `student_id`.

ТАБЛИЦА	КЛЮЧИ	СТРОК	КОЛОНОК	ЧТО ЭТО
`train`	`enrollment_id, student_id`	17 566	14	Записи студентов на потоки курсов с таргетом: курс, анкета студента, дата регистрации.
`test`	`enrollment_id, student_id`	8 837	13	Такие же записи без target. По ним нужен прогноз.
`courses`	`code_*`	22	3	Курсы и потоки: длина потока в днях.
`assessments`	`id_assessment, code_*`	206	6	Расписание заданий потока: тип, дедлайн, вес в итоговой оценке.
`student_assessment`	`enrollment_id, id_assessment`	51 295	5	Сданные до 60-го дня задания: когда сдано и с какой оценкой. Строка — одна сдача.
`vle`	`id_site, code_*`	6 364	6	Материалы курса в виртуальной образовательной среде: тип материала и плановые недели.
`student_vle`	`enrollment_id, id_site`	4,3 млн	4	Клики по материалам до 60-го дня. Строка — студент, материал и день.

Первые строки таблиц

train

ENROLLMENT_ID	STUDENT_ID	CODE_MODULE	CODE_PRESENTATION	TARGET	GENDER	REGION	HIGHEST_EDUCATION	IMD_BAND	AGE_BAND
100000	513236	FFF	2013J	1	M	Ireland	A Level or Equivalent	30-40%	0-35
100001	508970	FFF	2013J	0	F	East Midlands Region	Lower Than A Level	0-10%	35-55
100002	502897	CCC	2014B	1	M	Wales	HE Qualification	70-80%	35-55
100003	512816	FFF	2013B	1	M	West Midlands Region	Lower Than A Level	10-20	0-35
100007	520799	CCC	2014B	0	M	East Anglian Region	A Level or Equivalent	40-50%	0-35

test

ENROLLMENT_ID	STUDENT_ID	CODE_MODULE	CODE_PRESENTATION	GENDER	REGION	HIGHEST_EDUCATION	IMD_BAND	AGE_BAND	NUM_OF_PREV_ATTEMPTS
100004	509484	CCC	2014J	F	West Midlands Region	A Level or Equivalent	50-60%	35-55	0
100005	510474	BBB	2014J	F	Scotland	A Level or Equivalent	10-20	0-35	0
100006	513707	DDD	2014J	M	London Region	HE Qualification	90-100%	55<=	0
100013	512782	EEE	2014J	M	North Region	HE Qualification		35-55	1
100022	509983	FFF	2014J	M	Scotland	HE Qualification	60-70%	35-55	0

courses

CODE_MODULE	CODE_PRESENTATION	MODULE_PRESENTATION_LENGTH
AAA	2013J	268
AAA	2014J	269
BBB	2013J	268
BBB	2014J	262
BBB	2013B	240

assessments

CODE_MODULE	CODE_PRESENTATION	ID_ASSESSMENT	ASSESSMENT_TYPE	DATE	WEIGHT
AAA	2013J	1752	TMA	19	10
AAA	2013J	1753	TMA	54	20
AAA	2013J	1754	TMA	117	20
AAA	2013J	1755	TMA	166	20
AAA	2013J	1756	TMA	215	30

student_assessment

ENROLLMENT_ID	ID_ASSESSMENT	DATE_SUBMITTED	IS_BANKED	SCORE
100000	34873	19	0	62
100000	34874	47	0	68
100001	34873	18	0	56
100001	34878	37	0	64
100001	34874	46	0	68

vle

ID_SITE	CODE_MODULE	CODE_PRESENTATION	ACTIVITY_TYPE	WEEK_FROM	WEEK_TO
546943	AAA	2013J	resource		
546712	AAA	2013J	oucontent		
546998	AAA	2013J	resource		
546888	AAA	2013J	url		
547035	AAA	2013J	resource		

student_vle

ENROLLMENT_ID	ID_SITE	DATE	SUM_CLICK
100000	716217	-13	1
100000	716238	-13	1
100000	716351	-13	1
100000	716638	-13	1
100000	716645	-13	1

Показаны ключи и первые колонки. Пустая ячейка означает пропуск.

03

Метрика и сабмит

ROC AUC

```
AUC = P( score(не закончил) > score(закончил) )
```

Это вероятность того, что случайно взятый студент с `target = 1` получит от модели оценку выше, чем случайный студент с `target = 0`. Больше — лучше: 0,5 соответствует случайному угадыванию, 1,0 — идеальному разделению. Равные оценки считаются за половину.

Метрика зависит только от порядка прогнозов. `prediction` может быть вероятностью или любым числом, главное — чем больше значение, тем выше риск.

Формат сабмита

```
id,prediction
100123,0.4817
100124,0.2230
100131,0.9404
...
```

CSV, строка на каждую запись из `test.parquet` (8 837 строк). В колонке `id` — `enrollment_id` записи. Порядок строк не важен. Шаблон лежит в `sample_submission.csv`.

Public и private

Test скрыто разделён на две случайные части. **Public** (около 30% test) — по нему бот сразу показывает скор и строит лидерборд. **Private** — остальное, итоговые места считаются по нему после окончания соревнования.

Разница в третьем знаке AUC на public часто оказывается шумом. Ориентируйтесь на собственную валидацию.

Бейзлайны

РЕШЕНИЕ	PUBLIC ROC AUC
Baseline 1	0.64029
Baseline 2	0.77270
Baseline 3	0.79222

Бейзлайны тоже показаны в лидерборде бота.

04

Как сдавать через бота

Решения принимает Telegram-бот **@fcs_scoring_contest_bot**.

1 · /start

Откройте бота и отправьте `/start`.

2 · имя

Напишите имя и фамилию. Их видит только организатор.

3 · файл

Отправьте боту CSV-файл как документ.

4 · скор

Бот проверит формат и пришлёт public-скор и ваше место.

Команды

`/lb`	Лидерборд: лучший public-скор каждого участника
`/my`	Ваши решения с номерами и скорами
`/select`	Выбрать, какие из ваших решений (до двух) пойдут в финальный зачёт. После команды через пробел укажите номера решений из `/my`
`/name Имя Фамилия`	Сменить имя
`/rules`, `/help`	Правила и подсказка по формату

- **15 попыток в сутки**. Счётчик сбрасывается в 00:00 по Москве.
- Файл с ошибкой формата попытку не тратит: бот напишет, что исправить.
- В финальный зачёт идут выбранные через `/select` решения. Если ничего не выбрать, возьмутся два лучших по public.
- Каждое утро бот напоминает, сколько осталось до дедлайна.

Лидерборд анонимный

Вы видите своё имя и место. Остальные участники показаны под случайными кодами, бейзлайны — под своими названиями.

/lb

Public лидерборд · ROC AUC, больше — лучше

```
  #  ROC AUC участник               сабм
  1  0.xxxxx  Участник K7QD           11
▶ 2  0.xxxxx  Иван Петров (вы)        6
  3  0.xxxxx  Baseline 3              1
  4  0.xxxxx  Участник 3MRA           4
```

submission.csv

✓ Решение **#57** принято.
Public ROC AUC: **0.xxxxx**
Ваш лучший: 0.xxxxx, место 2
Осталось попыток сегодня: 9

Числа в примере условные.

05

Правила

- **Только выданные данные.** Можно использовать только файлы из архива. Любые внешние данные запрещены, в том числе исходный открытый датасет, из которого взяты данные, и любые другие размеченные выборки. Модели и библиотеки любые.
- **Проверка кода.** Участники из верхней части private лидерборда присылают код, который с нуля воспроизводит их сабмит из файлов архива. Если код не воспроизводит результат или нарушает правила, решение снимается.
- **Один участник — один аккаунт.** Обмен решениями между участниками запрещён.

Вопросы по задаче — организатору соревнования.

Данные: Kuzilek J., Hlosta M., Zdrahal Z. Open University Learning Analytics dataset. *Scientific Data* 4, 170171 (2017), лицензия CC BY 4.0. Для соревнования данные изменены: срез на 60-й день, новые идентификаторы, бинарный таргет, разбиение на train и test.